

UNIVERSIDADE FEDERAL FLUMINENSE
INSTITUTO DE COMPUTAÇÃO
SISTEMAS DE INFORMAÇÃO

MATHEUS NASCIMENTO MARCOS e ALEX DA SILVA ALVES

**DESENVOLVIMENTO DE SISTEMA DE APOIO A TOMADA DE DECISÃO:
UTILIZANDO CONCEITOS DE MODELAGEM MULTIDIMENSIONAL**

Niterói
2025

MATHEUS NASCIMENTO MARCOS e ALEX DA SILVA ALVES

**DESENVOLVIMENTO DE SISTEMA DE APOIO A TOMADA DE DECISÃO:
UTILIZANDO CONCEITOS DE MODELAGEM MULTIDIMENSIONAL**

Trabalho de conclusão de curso
apresentado ao curso de Bacharelado em
Sistemas de Informação, como requisito
parcial para conclusão do curso.

Orientador (a) (es):
Prof. Dr. Rodrigo Salvador Monteiro.

Niterói
2025

Ficha catalográfica automática - SDC/BEE
Gerada com informações fornecidas pelo autor

M321d Marcos, Matheus Nascimento
DESENVOLVIMENTO DE SISTEMA DE APOIO A TOMADA DE DECISÃO:
UTILIZANDO CONCEITOS DE MODELAGEM MULTIDIMENSIONAL / Matheus
Nascimento Marcos, Alex da Silva Alves. - 2025.
53 f.: il.

Orientador: Rodrigo Salvador Monteiro.
Trabalho de Conclusão de Curso (graduação)-Universidade
Federal Fluminense, Instituto de Computação, Niterói, 2025.

1. Modelagem Multidimensional. 2. Data Warehouse. 3. Suporte
a Tomada de Decisão. 4. ETL. 5. Produção intelectual. I.
Alves, Alex da Silva. II. Monteiro, Rodrigo Salvador,
orientador. III. Universidade Federal Fluminense. Instituto de
Computação. IV. Título.

CDD - XXX

MATHEUS NASCIMENTO MARCOS e ALEX DA SILVA ALVES

**DESENVOLVIMENTO DE SISTEMA DE APOIO A TOMADA DE DECISÃO:
UTILIZANDO CONCEITOS DE MODELAGEM MULTIDIMENSIONAL**

Trabalho de conclusão de curso
apresentado ao curso de Bacharelado em
Sistemas de Informação, como requisito
parcial para conclusão do curso.

Aprovada em 28 de janeiro de 2025 .

BANCA EXAMINADORA


Documento assinado digitalmente
 **RODRIGO SALVADOR MONTEIRO**
Data: 31/01/2025 09:17:25-0300
Verifique em <https://validar.it.gov.br>

u

Prof. Dr. Rodrigo Salvador Monteiro (Orientador) - UFF

Documento assinado digitalmente
 **DANIEL CARDOSO MORAES DE OLIVEIRA**
Data: 30/01/2025 12:44:53-0300
Verifique em <https://validar.it.gov.br>

Prof. Dr. Daniel Cardoso Moraes de Oliveira - UFF



Prof. Dr. Flávio Luiz Seixas - UFF



Prof. Dra. Elaine Ribeiro Sigette - UFF

Niterói
2025

AGRADECIMENTOS

Gostaríamos de agradecer a todos que contribuíram para este trabalho.

Agradecemos ao nosso orientador, Prof. Dr. Rodrigo Salvador Monteiro, pela ajuda e orientação em todo o estudo. Aprendemos intensamente com ele.

Agradecemos também ao Sérgio, que nos ajudou a entender melhor a parte técnica do sistema do PROLEM, tirando nossas dúvidas e nos dando dicas importantes.

E agradecemos à equipe do PROLEM por se disponibilizar para nos ajudar a entender o programa e o que poderíamos fazer para ajudar.

Agradecemos imensamente a todos.

RESUMO

Nessa monografia, é abordado o desenvolvimento de um ambiente de apoio à tomada de decisão utilizando conceitos de modelagem multidimensional. As informações dentro das organizações precisam cada vez mais serem acessíveis para suportar decisões estratégicas e o uso de *Data Warehouses* e técnicas de análises de dados tem se tornado cada vez mais essencial. Neste trabalho, exploramos os principais conceitos que se aplicam na construção de um sistema para tomada de decisão, incluindo fatos, dimensões, esquemas, o processo de Extração, Transformação e Carga (ETL), técnicas de Slowly Changing Dimensions e arquitetura de barramento. Todos esses conceitos foram aplicados no contexto do Programa de Línguas Estrangeiras Modernas (PROLEM), que serviu como estudo de caso para a validação das técnicas. O objetivo principal é conhecer e explorar como a modelagem multidimensional, ao ser aplicada no cenário real do PROLEM, pode transformar dados brutos em informações relevantes para a tomada de decisão, permitindo que as organizações compreendam melhor seus negócios e tomem decisões mais assertivas.

Palavras-chave: Modelagem Multidimensional. *Data Warehouse*. ETL. Extração de Dados. Transformação de Dados. Carga de Dados. Slowly Changing Dimensions. Arquitetura de Barramento. Tomada de Decisão.

ABSTRACT

This monograph addresses the development of a decision-making support environment using multidimensional modeling concepts. Information within organizations needs to be increasingly accessible to support strategic decisions, and the use of Data Warehouses and data analysis techniques has become increasingly essential. In this work, we explore the main concepts that apply to the construction of a decision-making system, including facts, dimensions, schemas, the Extraction, Transformation and Loading (ETL) process, Slowly Changing Dimensions techniques and bus architecture. All these concepts were applied in the context of the Modern Foreign Languages Program (PROLEM), which served as a case study for the validation of the techniques. The main objective is to understand and explore how multidimensional modeling, when applied in the real PROLEM scenario, can transform raw data into relevant information for decision-making, allowing organizations to better understand their business and make more assertive decisions.

Keywords: Multidimensional Modeling. Data Warehouse. ETL. Data Extraction. Data Transformation. Data Loading. Slowly Changing Dimensions. Bus Architecture. Decision Making.

LISTA DE ILUSTRAÇÕES

Figura 1 –	Ilustração <i>Data Warehouse</i>	15
Figura 2 –	Exemplo de fluxo de dados de um DW	17
Figura 3 –	Ilustração de modelagem em esquema estrela	23
Figura 4 –	Exemplo de modelagem em esquema floco de neve	25
Figura 5 –	Ilustração do processo de ETL	26
Figura 6 –	Exemplo de arquitetura de barramento - Seus processos de negócio e suas diferentes dimensões comuns ou não de análise	28
Figura 7 –	Exemplo de aplicação do SCD do Tipo 2 - Tabela de clientes fonte e dimensão clientes com campos adicionados para permitir alteração	30
Figura 8 –	Exemplo de aplicação do SCD do Tipo 2 - Alteração na tabela de clientes fonte e na dimensão clientes	31
Figura 9 –	Exemplo de operação de slice	32
Figura 10 –	Exemplo de operação de dice	33
Figura 11 –	Exemplo de operações OLAP	34
Figura 12 –	Ilustração da Modelagem final feita	39
Figura 13 -	Modelo Lógico do DW	40
Figura 14 -	Diagrama de estados	44
Figura 15 -	ETL da fato - Parte 1	47
Figura 16 -	ETL da fato - Parte 2	47
Figura 17 -	Integração de dados do DW com Power BI	48
Figura 18 -	Tabelas carregadas no Power BI	48

Figura 19 – Dashboard finalizado

49

LISTA DE TABELAS

Tabela 1 –	Características de um DW bem-sucedido	16
Tabela 2 –	Características de uma tabela fato	20
Tabela 3 –	Tipo de métricas	20
Tabela 4 -	Características de uma tabela de dimensão	21

LISTA DE ABREVIATURAS E SIGLAS

Abreviatura/Sigla	Definição
CRM	<i>Customer Relationship Management</i>
DTE	Diagrama de Transição de Estados
DW	<i>Data Warehouse</i>
ERP	<i>Enterprise Resource Planning</i>
ETL	<i>Extract, Transform and Load</i>
HOLAP	<i>Hybrid Online Analytical Processing</i>
MOLAP	<i>Multidimensional Online Analytical Processing</i>
OLAP	<i>Online Analytical Processing</i>
OLTP	<i>On-Line Transaction Processing</i>
PROLEM	Programa de Línguas Estrangeiras Modernas
ROLAP	<i>Relational Online Analytical Processing</i>
SAD	Sistemas de Apoio à Tomada de Decisão
SCD	<i>Slowly Changing Dimensions</i>
SQL	<i>Structured Query Language</i>
UFF	<i>Universidade Federal Fluminense</i>

SUMÁRIO

1 INTRODUÇÃO.....	13
2 FUNDAMENTAÇÃO TEÓRICA SOBRE DATA WAREHOUSE.....	14
2.1 Data Warehouse.....	14
2.1.1 Fluxo de Dados em um DW.....	17
2.2.1 Fato.....	19
2.2.2 Dimensão.....	21
2.2.3 Relação entre Fatos e Dimensões.....	22
2.2.4 ROLAP: Implementação da Modelagem Dimensional.....	22
2.3 Staging Area.....	25
2.4 Arquitetura de Barramento.....	27
2.5 Slowly Changing Dimensions.....	28
2.5.1 Tipos de técnicas para tratamento.....	29
2.6 Ferramentas OLAP.....	31
3 METODOLOGIAS APLICADAS.....	35
3.1 Metodologias.....	35
3.2 Projeto Piloto.....	37
3.2.1 Etapas do projeto piloto.....	37
4 ESTUDO DE CASO.....	42
4.1 Preparação e descaracterização dos dados.....	42
4.2 Entendendo o sistema do estudo de caso e definindo assuntos de interesse.....	43
4.3 Desenvolvimento do Diagrama de Transição de estados (DTE).....	44
4.4 Modelagem Multidimensional.....	45
4.5 ETL.....	45
4.6 Carregamento para ferramenta OLAP.....	48
5 CONCLUSÃO.....	50

1 INTRODUÇÃO

O objetivo dessa monografia é apresentar os conceitos e técnicas da modelagem multidimensional aplicada ao desenvolvimento de Sistemas de Apoio à Tomada de Decisão (SAD), com ênfase na transformação de dados brutos em informações estratégicas para as organizações. Para isso, o estudo utiliza como cenário real o Programa de Línguas Estrangeiras Modernas (PROLEM) da Universidade Federal Fluminense (UFF), um programa importante para o ensino de idiomas, no qual enfrenta desafios na sua gestão de dados.

O PROLEM é responsável por oferecer cursos de línguas estrangeiras em diversos níveis e idiomas. O programa atua em um ambiente complexo desde a inscrição, matrícula, até a conclusão do aluno, onde as decisões precisam ser estratégicas, para alocar recursos, otimizar turmas e reduzir a evasão. No entanto, o PROLEM carece de mecanismos eficientes para analisar seus dados operacionais. Atualmente, informações essenciais, como taxas de conversão de inscrições em matrículas, taxas de evasão, entre outros indicadores, são gerados manualmente de forma segmentada. A ausência de ferramentas que permitam a análise de dados, dificulta uma tomada de decisão baseada em evidências. Diante desse contexto, surge a necessidade de um sistema que transforme dados dispersos em insights estratégicos.

O texto segue a seguinte organização: inicialmente, apresentamos as fundamentações teóricas no capítulo 2 sobre os conceitos e técnicas aplicadas ao longo do projeto. Em seguida, detalhamos as principais etapas e metodologias que foram aplicadas no capítulo seguinte. Posteriormente, discutimos a aplicação prática desses conceitos no estudo de caso do PROLEM, detalhado no capítulo 4. E por fim, a conclusão do estudo e as perspectivas tiradas do processo.

2 FUNDAMENTAÇÃO TEÓRICA SOBRE DATA WAREHOUSE

Este capítulo introduz os conceitos e princípios que sustentam a construção de um DW. Nele, abordam-se conceitos para modelagem multidimensional do mesmo, além de abordar suas áreas existentes e como elas se encaixam na elaboração de um ambiente de apoio à tomada de decisão. Discute-se sobre o processo de definição de assuntos de interesse e modelagem, como anteriormente dito, até a passagem pela *Staging Area* e pelo processo de ETL para se preparar os dados para a carga no DW. E com os dados carregados estes são disponibilizados para, por exemplo, exploração e análise através de ferramentas OLAP. Também são discutidas técnicas de SCD (*Slowly Changing Dimensions*) para lidar com as mudanças nos dados ao longo do tempo e como utilizar tais conceitos nas cargas incrementais. Estratégias de arquitetura de barramento são expostas visando auxiliar o desenvolvimento de novos esquemas que irão enriquecer a modelagem inicial com mais assuntos a serem analisados pelos usuários finais.

2.1 *Data Warehouse*

Conforme definem KIMBALL e ROSS (2011), um *Data Warehouse* é a união das áreas de preparação e apresentação de dados de uma organização. Ele é um ambiente onde dados operacionais são estruturados especificamente para desempenho em consultas e análises, além de facilidade de uso. Enquanto os sistemas operacionais são projetados para capturar e registrar transações em tempo real, o DW tem como objetivo principal armazenar e organizar dados históricos para análise e tomada de decisão. A diferença fundamental entre os dois reside em seus propósitos: um foca nas operações diárias, enquanto o outro visa fornecer insights estratégicos.

O *Data Warehouse* armazena dados de diversas fontes, processa e organiza essas informações para fornecer uma visão integrada e histórica do negócio. A partir da análise dos dados, utilizando diversas ferramentas e técnicas, os usuários podem extrair insights, gerar conhecimento e tomar decisões mais eficazes em todos os níveis da organização.




Figura 1 - Ilustração *Data Warehouse*

Fonte : Adaptado de Código Fonte TV, 2024

Segundo, (KIMBALL; ROSS, 2011), um *Data Warehouse* bem-sucedido deve ter os seguintes objetivos:

Tabela 1 - Características de um DW bem-sucedido

Tornar as informações de uma organização facilmente acessíveis.	O <i>Data Warehouse</i> . deve ser uma ferramenta acessível e intuitiva, colocando o poder da análise de dados nas mãos de todos os colaboradores, independentemente de seu conhecimento técnico.
Apresentar as informações da organização de forma consistente.	O <i>Data Warehouse</i> deve ser um repositório de dados confiável e consistente, garantindo que as informações sejam precisas, completas e livres de discrepâncias, independentemente da fonte.
Ser adaptável e resiliente a mudanças.	O <i>Data Warehouse</i> deve ser flexível o suficiente para acomodar as mudanças inevitáveis nos requisitos de negócio e nas tecnologias, sem exigir uma reengenharia completa.
Ser um bastião seguro que proteja nossos ativos de informação.	O <i>Data Warehouse</i> armazena informações críticas para a organização, por isso é essencial implementar medidas de segurança robustas para proteger esses dados contra acesso não autorizado.
Servir como base para uma melhor tomada de decisão.	O verdadeiro valor do <i>Data Warehouse</i> reside nos resultados concretos que ele proporciona, ou seja, nas decisões mais

	acertadas tomadas graças às informações disponíveis.
Ser aceito pela comunidade empresarial, para ser considerado bem sucedido.	Para ser considerado bem-sucedido, o <i>Data Warehouse</i> precisa ser amplamente utilizado e aceito pela comunidade da organização.

Fonte: Adaptado de KIMBALL;ROSS, 2011

2.1.1 Fluxo de Dados em um DW




Figura 2 - Exemplo de fluxo de dados de um DW

Fonte: Adaptado de KIMBALL;ROSS, 2011

Fontes - São os sistemas onde os dados são gerados inicialmente. Podem ser sistemas de transações (como um sistema de ponto de venda), sistemas de CRM (*Customer Relationship Management*), ERP (*Enterprise Resource Planning*), entre outros.

Data Staging Area - Nesta etapa, os dados passam por um processo de transformação conhecido como ETL, que iremos aprofundar na seção 2.3. A extração envolve a coleta dos dados das fontes, a transformação consiste em limpar, padronizar e transformar os dados para um formato adequado ao *Data Warehouse*, e a carga consiste em inserir os dados transformados na área de apresentação.

Data Presentation Area - É a área onde os dados são organizados e estruturados de forma a facilitar a consulta e a análise. Os dados são organizados por assunto de interesse para monitoramento e tomada de decisão

Ferramenta de Acesso - São as ferramentas que os usuários utilizam para acessar e analisar os dados armazenados no *Data Warehouse*. Permitem a criação de relatórios, gráficos, *dashboards* e análises *ad-hoc*, auxiliando na tomada de decisões.

Em suma, o *Data Warehouse* funciona como um depósito centralizado de dados, coletando informações de diversas fontes operacionais. Inicialmente, esses dados são extraídos e direcionados para a *Staging Area*, onde passam por processos de limpeza, transformação e padronização. Após essa preparação, os dados são carregados no *Data Warehouse*, onde são organizados em uma estrutura dimensional que facilita a análise. As ferramentas de acesso, como ferramentas OLAP, permitem que os usuários explorem esses dados de forma interativa, criando relatórios, visualizações e insights personalizados conforme a necessidade dos interessados.

2.2 Modelagem Dimensional

A Modelagem Dimensional é uma técnica para a apresentação dos dados em um *Data Warehouse*, organizando-o em uma estrutura específica, facilitando a análise e a extração de insights, para que seja de fácil entendimento aos usuários do *Data Warehouse*, afinal, muitos dos usuários de um DW são da área de negócio da organização e não usuários técnicos (KIMBALL; ROSS, 2011).

O foco da Modelagem Dimensional organiza os dados em uma estrutura que facilita o entendimento humano, diferentemente do que vamos encontrar no sistema da fonte dos dados de onde eles são por muitas vezes organizados na Terceira Forma Normal (3FN). Na 3FN, o banco de dados está organizado de maneira que evita anomalias no banco de dados, de maneira que elimine a possibilidade de valores inconsistentes, redundâncias e estabelecendo uma relação sólida entre as entidades/tabelas do banco de dados, mas não necessariamente é a melhor maneira de ser visualizado por humanos, mas sim, é a melhor maneira de ser operado por sistemas evitando alguns problemas. Já a Modelagem Dimensional, busca focar na melhor visualização para um humano, de maneira flexível aos usuários manipular conforme as suas necessidades. E por isso surge essa modelagem para que os dados sejam organizados de maneira entendível para análises e insights. A estrutura da Modelagem Dimensional se baseia em dois componentes principais: Fatos e Dimensões.

2.2.1 Fato

O fato é a tabela central de um *Data Warehouse* dimensional que é relacionado a diferentes tabelas dimensões. Ela armazena as medidas numéricas que representam os fatos de negócio que queremos analisar, como vendas, custos, quantidade, etc. Os fatos possuem as seguintes características importantes:

Tabela 2 - Características de uma tabela de fato

Granularidade	Refere-se ao nível de detalhe no qual os fatos são medidos. A granularidade é determinada pelas dimensões associadas ao fato.
Aditividade	A maioria dos fatos são aditivos, o que significa que podem ser somados ao longo de diversas dimensões permitindo agregações e análises mais complexas.
Valores Contínuos	Os fatos normalmente assumem valores numéricos contínuos.

Fonte: Adaptado de KIMBALL;ROSS, 2011

As métricas utilizadas para medir os fatos podem ser classificadas como:

Tabela 3 - Tipo de métricas

Métricas Aditivas	São métricas que podem ser agregadas em qualquer nível de granularidade, como o valor total de vendas.
Métricas Semi-Aditivas	São métricas que podem ser agregadas em alguns níveis de granularidade, mas não em outros, como o saldo de uma conta bancária.

Métricas Não Aditivas	São métricas que não podem ser agregadas em nenhum nível de granularidade, como média e percentuais.
------------------------------	--

Fonte: Adaptado de KIMBALL;ROSS, 2011

2.2.2 Dimensão

As dimensões fornecem o contexto para os fatos, representando as categorias de dados que descrevem os eventos. Cada dimensão pode ser tempo (ano, mês, dia), produto (categoria, marca), cliente (região, idade), etc. As dimensões são responsáveis por adicionar significado aos fatos, facilitando a análise de dados. As principais características das dimensões são:

Tabela 4 - Características de uma tabela de dimensão

Atributos Textuais	Descrições detalhadas dos elementos de negócio.
Hierarquias	Muitas dimensões possuem hierarquias (ex: "Produto" > "Categoria" > "Marca").

Fonte: Adaptado de KIMBALL;ROSS, 2011

A função das dimensões é fornecer o contexto para as medidas numéricas, permitindo aos analistas compreender o significado dos dados, explorar diferentes perspectivas e responder a perguntas de negócio.

2.2.3 Relação entre Fatos e Dimensões

Os fatos são relacionados às dimensões através de chaves, criando uma relação que possibilita a análise dos dados sob diversas perspectivas e flexibilidade para as necessidades de cada usuário interessado na informação.

Para a implementação da Modelagem Dimensional, será utilizado um esquema relacional baseado na abordagem ROLAP (*Relational Online Analytical Processing*). Esta abordagem estrutura os dados em um modelo relacional tradicional, com fatos e dimensões armazenados em tabelas interligadas por chaves estrangeiras, o que permite uma grande flexibilidade e escalabilidade para a análise de dados.

2.2.4 ROLAP: Implementação da Modelagem Dimensional

Para a implementação da Modelagem Dimensional, neste estudo escolhemos utilizar um esquema relacional baseado na abordagem ROLAP (*Relational Online Analytical Processing*). Conforme mencionado anteriormente, a modelagem dimensional define os conceitos de fatos e dimensões, mas sua implementação no armazenamento dos dados pode ser feita de diferentes maneiras. Neste tipo de modelagem, os dados são estruturados em tabelas relacionais, onde os fatos são armazenados em uma tabela central com medidas numéricas, e as dimensões são armazenadas em tabelas separadas com atributos descritivos.

A escolha dessa abordagem justifica-se pela sua capacidade de lidar com grandes volumes de dados e pela sua flexibilidade. Além disso, ele permite que as ferramentas de análise OLAP realizem consultas complexas através de SQL. A estratégia de modelagem relacional transforma os dados em um formato mais acessível e útil para a análise

multidimensional, que é um dos objetivos do trabalho. Essa abordagem garante que, mesmo utilizando o conceito de fatos e dimensões, os dados possam ser armazenados e acessados utilizando a estrutura de tabelas de um banco de dados relacional, facilitando integrações com ferramentas de análise de dados.

E embora a abordagem ROLAP seja o foco deste trabalho, (KIMBALL; ROSS, 2011) destacam que existem outras arquiteturas OLAP, como MOLAP (*Multidimensional OLAP*) e HOLAP (*Hybrid OLAP*), cada uma com suas características e adequações, que não abordaremos nesta monografia.

2.2.5 Esquemas

Na modelagem multidimensional, temos algumas abordagens de estruturação dos dados, ou seja, a forma como eles serão dispostos e relacionados em tabelas fatos e dimensões que irão variar de acordo com o esquema escolhido e que irão caracterizar uma representação de um assunto ou fato de interesse, que em conjunto, podem representar e caracterizar um negócio, processo, ou uma organização, como assim caracteriza Ralph Kimbal (1996). Temos algumas formas de modelagem sendo elas o Esquema Estrela (*Star Schema*) e Esquema Floco de Neve (*Snow Flake Schema*) os mais predominantes.




Figura 3: Ilustração de modelagem em esquema estrela

Fonte: Caderno de Prova (2021)

A modelagem através do esquema estrela como mostra a figura 3, tem um tabela de fato central ligada a diferentes tabelas dimensões numa estrutura desnormalizada, ou seja, que não se preocupa com a redundância de dados e sim com a facilitação e otimização de consultas. Tendo uma tabela de fato normalizada que contém as métricas, que não irão se repetir e por isso a tabela é considerada normalizada, como mostradas na figura escritas em azul na tabela de fato vendas.

Ainda é possível notar as chaves estrangeiras (FK) para as dimensões e a chave primária (PK) composta pela combinação das FK's, o que garante que nosso fato possa ser analisado sobre diferentes dimensões, a qual se relaciona de diferentes maneiras. Formando-se assim uma estrela, que terá um assunto central a ser analisado como é o tema Vendas no exemplo da Figura 3, sendo analisado o lucro e a quantidade de unidades vendidas em um determinado tempo, para um produto ou filial, sendo estes nossos ângulos de análise do fato.

Já no modelo Floco de Neve (*Snow Flake Schema*) temos uma abordagem de modelagem multidimensional que assim como o *Star Schema* se preocupa em facilitar a análise de um fato, através da estruturação das tabelas porém que se preocupa também com a redundância dos dados. Assim como o esquema estrela, o floco de neve possui uma ou mais tabelas de fato que se ligam a outras tabelas de dimensão porém nesse tipo de representação existe a preocupação em normalizar os dados das tabelas de dimensão criando-se assim uma hierarquia de dimensões por assim dizer, ou seja, as tabelas de dimensão podem ter uma relação com outra tabela de dimensão que irá evitar redundância de dados nas dimensões e assim otimizar armazenamento e também pode descrever cenários que envolvem maior complexidade de dados e análises.




Figura 4: Exemplo de modelagem em esquema floco de neve

Fonte: Galvão (2023)

2.3 Staging Area

A *Staging Area* é um componente essencial para o processo ETL. Segundo definem (KIMBALL; ROSS, 2011), a mesma é uma área intermediária onde os dados são armazenados temporariamente, e é a partir dessa área, com os dados da fonte original, que são feitos os tratamentos necessários, antes de serem inseridos no DW. Ao contrário da visão de que os dados são armazenados em uma tabela temporária, a *Staging Area* é uma região de armazenamento que possibilita tratar os dados de forma independente da fonte original, o que aumenta a performance do processo de tratamento e evita sobrecarregar a fonte de dados com consultas frequentes. Sendo a área de preparação dos dados, onde eles são limpos, transformados e padronizados.

Na prática, os dados são copiados das fontes originais para a *Staging Area*. Em seguida, são aplicadas diversas transformações, como:

- **Limpeza:** Remoção de erros, duplicatas e valores inconsistentes.
- **Padronização:** Unificação de formatos, unidades de medida e outros elementos.
- **Transformação:** Criação de novas colunas, cálculos e agregação de dados.

Na figura abaixo podemos ver por outro ângulo essa visão geral do processo ETL e onde a *Staging Area* se encaixa no processo.




Figura 5 - Ilustração do processo de ETL

Fonte: SANTANA (2024)

Assim sendo, o processo de ETL, ou Extração, Transformação e Carga, consiste em um conjunto de etapas para a preparação dos dados antes de sua inserção no *Data Warehouse*. Essas etapas garantem que os dados brutos, gerados de diversas fontes de sistemas operacionais, sejam transformados em informações consistentes e adequadas para análise no DW.

Extração: Nesta etapa, os dados brutos são coletados das fontes originais, como sistemas ERP, bancos de dados e arquivos.

Transformação: É a etapa onde os dados extraídos são limpos, padronizados, formatados e integrados na *Staging Area*. Processos como a correção de erros, a remoção de duplicados, a criação de novas variáveis e a agregação de dados são comuns nessa etapa do

processo. Para que assim esses dados sejam tratados para fazer a carga para o *Data Warehouse*.

Carga: Por fim, os dados transformados são carregados no *Data Warehouse*, onde serão armazenados e disponibilizados para análise.

2.4 Arquitetura de Barramento

Como vimos ao desenvolver uma modelagem seja ela por esquema estrela ou floco de neve a ideia é desenvolver uma estrutura de tabelas que irão descrever fatos, ou seja, um conjunto de assuntos de interesse em determinados fatos que caracterizam um evento maior. E para descrever cada um desses elementos de um conjunto é necessário a criação de diferentes estrelas ou flocos que terão dimensões, ou seja, análises por ângulos em comum.

Por exemplo, para uma loja de roupas é necessário entender dados sobre seu processo de venda e o mesmo vale para entender seus gastos com inventário e demais processos que ocorrem nesse tipo de negócio para possibilitar uma análise do desempenho da loja como um todo. Logo, é comum que exista algum tipo de relacionamento entre dimensões com diferentes tabelas de fato e o que definimos como arquitetura de barramento se dá através da decomposição do *Data Warehouse* em vários *Data Marts* que descrevem cada fato de interesse definido no processo de modelagem, e que geram a modelagem de esquemas que se interligam por tabelas de dimensões comuns a mais de uma tabela de fato. Um bom exemplo é a dimensão tempo que é inerente em quase toda análise de um fato.

E ao definir uma interface de barramento padrão para o ambiente DW, modelos dimensionais separados podem ser implementados por diferentes grupos em momentos diferentes. Deste modo, as áreas de negócio distintas podem se conectar e coexistir de maneira complementar.




Figura 6: Exemplo de arquitetura de barramento - Seus processos de negócio e suas diferentes dimensões comuns ou não de análise

Fonte: LOPES (2024)

2.5 *Slowly Changing Dimensions*

Em um *Data Warehouse* (DW) estamos sujeitos a mudanças que ocorrem em nossas fontes de dados ao longo do tempo, como por exemplo a atualização de um endereço de um cliente cadastrado na base de clientes pois o mesmo se mudou ou a mudança de nome ou preço de um produto ao longo do tempo, ambos são exemplos comuns e que acontecem normalmente com o passar do tempo além de vários outros passíveis de ocorrer no dia a dia.

Muitas dessas mudanças são mais possíveis de acontecer em tabelas de dimensão pois essas são compostas de dados descritivos que como citado nos exemplos anteriormente são passíveis a serem corrigidos ou alterados, daí então o surgimento do termo de SCD (*Slowly Changing Dimensions*) que diz respeito às mudanças que ocorrem lentamente em nossas fontes de dados das dimensões e sendo um dos temas a ser abordado por gestores e administradores do DW, a definição do tipo de estratégia de resposta a essas mudanças pelo sistema de armazenamento de dados projetado é também tarefa dos representantes do processo de negócio ou organização envolvida como defendem Ross (2013).

2.5.1 Tipos de técnicas para tratamento

Foram desenvolvidas algumas técnicas de tratamento para lidar com essas mudanças, sendo classificadas por números de tipo em vez de por nomeação, com o objetivo de facilitar a comunicação mais clara entre membros de uma equipe de desenvolvimento do DW/BI, como cita Ross (2013), e sendo elas do tipo 0,1,2 e entre outras, sendo as anteriormente citadas as mais comumente usadas para tratar as mudanças nas dimensões.

Na técnica SCD, do tipo 0, as mudanças dos valores dos atributos da dimensão não irão refletir no DW, ou seja uma vez que o mesmo é carregado com dados o mesmo irá manter esses dados originais mesmo que algum registro carregado sofra mudança na fonte de dados ao longo tempo sendo útil então quando se deseja manter os dados originais.

Já no tipo 1 e os demais, a mudança na fonte de dados irá refletir no DW de maneiras diferentes. Onde no tipo 1, temos a seguinte estratégia quando a mudança acontece na fonte e acontece o processo de carga da fonte para o DW a mudança no campo alterado na fonte irá ser propagada ao DW de forma que a informação original antes presente no campo será substituída pela formação alterada considere o exemplo de uma tabela de dimensão cliente e o mesmo muda seu endereço ao ocorrer o processo da carga o endereço original será substituído pelo novo endereço logo nesse tipo de técnica é visível a perda de histórico do endereço do cliente então a técnica é útil para mudanças que não exigem que se guarde histórico e para manter o dado em tempo real com a fonte de dados.

Visto a necessidade de em alguns casos guardamos o histórico, surge a necessidade das técnica de SCD do tipo 2, onde temos a criação de um novo registro na dimensão e para isso é necessário que generalizemos a chave primária da tabela dimensão, ou seja através da criação de uma chave primária sequencial na tabela e está mantendo a chave identificadora do registro como um dos seus atributos, mas dessa forma é possível ter registros com mesmo identificador, caso do ID Cliente na figura 7, por exemplo, mas sem violar o conceito da chave primária ser única, pois, foi criado uma chave sequencial, SK Cliente, no exemplo da figura 7, que serve como chave substituta. E além disso, faz-se necessária a criação de um

campo de validade do campo para indicar dessa forma quando houve mudança e se o mesmo é o dado mais atual, em caso de não ter data de validade e muitas vezes pode ser usado um campo de flag para o registro ser o mais atual ou não.

Vale ressaltar também a criação de um campo na fonte de dados modificado como na figura que irá marcar quando o campo foi alterado e irá facilitar ao carregar a data de validade do campo original e de efetividade do novo campo como demonstrado na figura 8. A técnica de SCD Tipo 2, descrita nesta seção, foi aplicada no PROLEM para rastrear alterações nas matrículas ao longo do tempo, conforme detalhado no capítulo 4.

ID Cliente	Nome	Cidade	Modificado
20	João da Silva	Rio de Janeiro	10/04/2015

Table 11 Tabela Clientes

SK Cliente	Efetivo	Expirado	Atual	ID Cliente	Nome	Cidade (SCD Tipo 2)
1	10/04/2015	NULL	1	20	João da Silva	Rio de Janeiro

Figura 7: Exemplo de aplicação do SCD do Tipo 2 - Tabela de clientes fonte e dimensão clientes com campos adicionados para permitir alteração.

Fonte: AVANCINI (2024)

ID Cliente	Nome	Cidade	Modificado
20	João da Silva	São Paulo	8/06/2016

Table 13 Tabela Clientes (atualizada)

SK Cliente	Efetivo	Expirado	Atual	ID Cliente	Nome	Cidade (SCD Tipo 2)
1	10/04/2015	8/06/2016	0	20	João da Silva	Rio de Janeiro
2	8/06/2016	NULL	1	20	João da Silva	São Paulo

Table 14 Tabela Dim Clientes (atualizada)

Figura 8: Exemplo de aplicação do SCD do Tipo 2 - Alteração na tabela de clientes fonte e na dimensão clientes.

Fonte: AVANCINI (2024)

2.6 Ferramentas OLAP

As ferramentas OLAP (*Online Analytical Processing*), são utilizadas a fim de facilitar o acesso à informação para os usuários finais do DW. Estas ferramentas suportam um grande volume de dados e tornam a apresentação mais amigável, possibilitando que sejam gerados relatórios, além da obtenção de informações estratégicas e do apoio às mais diferentes tomadas de decisões por diferentes dimensões (Devmedia, 2008). Diferentemente de ferramentas OLTP (*On-Line Transaction Processing*) que são voltadas para armazenar e executar transações do cotidiano de forma ágil e otimizada.

Logo pode se perceber que o OLAP é voltado para permitir análises e suportar decisões gerenciais e estratégicas usando modelos multidimensionais (cubos) na estruturação dos dados permitindo assim análise mais sofisticadas. E através do cubo de informações, podem ser feitas diferentes operações que irão permitir que seja gerado um subconjunto parcial de informações do cubo permitindo a variação de análises de acordo com a necessidade de visualização do usuário e restringindo em tempo de consulta um alto volume de dados em um subconjunto de interesse.

As principais operações das ferramentas OLAP são a de *slice*, *dice*, *drill down*, *drill up*. Onde as operações de *slice* e *dice* manipulam as dimensões do cubo e a seleção de um subconjunto menor de informações, no *slice* temos a fixação de uma das dimensões em um valor fixo a ser analisado em relação a todo conjunto das dimensões restantes, como no exemplo da figura 9, considere numa modelagem de venda de produtos onde temos um produto P2, sendo analisado em relação a todos os valores da dimensão de tempo e região proporcionando uma análise de venda do produto P2, para todo período de tempo da dimensão tempo para cada região da dimensão de região trazendo assim uma fatia do cubo.




Figura 9: Exemplo de operação de *slice*.

Fonte: ROCHA (2021)

Já na operação de *dice* temos um seleção de um subcubo do cubo formado a partir da seleção de filtro de valores em múltiplas dimensões, pensando no mesmo exemplo passado poderíamos segmentar o cubo original em um menor filtrando a dimensão produto em P3 e P4 e as dimensões de tempo e região em um ou mais valores simultaneamente resultando na análise de vendas do produto 3 e 4 como na figura 10 por exemplo.




Figura 10: Exemplo de operação de *dice*.

Fonte: ROCHA (2021)

Já nas operações de *drill down* e *drill up* temos um aumento ou diminuição da granularidade das informações das dimensões, ou seja, um avanço ou diminuição na hierarquia dos dados, onde no *drill down* temos a diminuição da granularidade, ou seja, imagine que temos uma dimensão de tempo por ano e queremos analisar de forma mensal usando a operação, podemos reduzir o grão da dimensão tempo para acompanhar de forma mensal o assunto de interesse.

Enquanto no *drill up* temos a situação oposta ou seja o aumento da granularidade da dimensão. Pense em um exemplo onde estamos analisando vendas por estado, mas desejamos fazer a análise por região, utilizamos esta operação para avançar na hierarquia de estados para região passando a analisar o fato de interesse venda num grão maior, que seria o de região ao invés da análise por estados.

Além ainda de operações como o *roll-up* que agrega ou sumariza dados do cubo, por exemplo, sumarizando os dados de venda para cada período de tempo da dimensão. E a operação de *pivot*, que envolve alterar as dimensões entre colunas e linhas. Imagine que se tem as informações de tempo em linhas e de produtos por colunas ao fazer a operação de pivot podemos alternar a informação de tempo para coluna e produtos para linhas permitindo outra forma de análise.




Figura 11: Exemplo de operações OLAP.

Fonte: WIKIPÉDIA (2024)

3 METODOLOGIAS APLICADAS

No capítulo anterior, apresentamos a fundamentação teórica sobre Data Warehouse. Neste capítulo, detalharemos as metodologias aplicadas no desenvolvimento do projeto. A metodologia geral do projeto foi estruturada nas seguintes etapas:

- **Estudo Teórico e Conceitual:**
 - Realização de um estudo aprofundado sobre os conceitos e técnicas de *Data Warehouse* e modelagem multidimensional.
- **Desenvolvimento de um Caso Piloto:**
 - Implementação de um caso piloto utilizando uma base de dados pública para testar ferramentas e metodologias aprendidas.
- **Aplicação dos conhecimentos e ferramentas adquiridos em um cenário real:**
 - Para validar a solução proposta e avaliar seu impacto no negócio.

A seguir, detalharemos cada uma dessas etapas e as metodologias específicas que foram aplicadas em cada uma delas.

3.1 Metodologias

O desenvolvimento deste projeto foi estruturado em uma progressão de aprendizado, que envolveu primeiramente um estudo teórico aprofundado, seguido pela aplicação prática dos conceitos aprendidos em um cenário inicial e, por fim, a aplicação em um cenário real. O estudo teórico nos permitiu compreender as nuances da modelagem multidimensional e suas aplicações no contexto de *Data Warehouses* e Sistemas de Apoio à Tomada de Decisão. A partir dessa base teórica, buscamos uma experiência prática para solidificar o conhecimento.

Para a prática inicial, escolhemos a base de dados pública do sistema de E-commerce Olist, disponível no Kaggle. Essa experiência serviu para aplicarmos na prática a teoria estudada, consolidando o nosso entendimento sobre as metodologias necessárias para a criação de um ambiente de tomada de decisão. Durante a prática no cenário do Olist,

identificamos que a criação de um ambiente de tomada de decisão segue as seguintes etapas principais:

- Entendimento da Estrutura da Fonte de Dados:
 - Inicialmente, ao ter uma base de dados em mãos para trabalhar, foi de suma importância entender sua estrutura. Isso envolve caracterizar o ambiente, não apenas em termos de volume e cobertura de dados, mas também compreendendo o que cada tabela representa e seus relacionamentos com outras tabelas. O objetivo era entender a base de dados em profundidade, possibilitando o próximo passo: a definição dos assuntos de interesse.
- Definição de Assuntos de Interesse:
 - O passo seguinte foi definir os possíveis insights e entender a cobertura de dados e informações disponíveis para então gerar uma modelagem do nosso DW. Isso envolveu modelar as tabelas de dimensão e de fato para a construção de um primeiro esquema.
- Modelagem Multidimensional:
 - Durante o projeto, aprimoramos o conhecimento do esquema estrela e utilizamos esse modelo de construção de esquema desnormalizado em nossas modelagens. É neste momento que definimos os atributos característicos das tabelas de dimensão e as métricas da tabela de fato. Definimos também se seriam utilizadas métricas aditivas, semi-aditivas ou não aditivas, com base nas informações da base de dados. Também definimos a estrutura das tabelas de dimensão para possibilitar ou não o carregamento das mudanças nas informações ao longo do tempo, implementando chaves primárias automaticamente geradas para registrar as mudanças sem violar o conceito de chave primária única. Portanto, abordando também as técnicas de *Slowly Changing Dimensions* (SCD).
- Construção do DW e da Staging Area:
 - Com o sistema modelado, o próximo passo foi a construção do DW e da *Staging Area*. A partir daí iniciamos a fase de ETL. Utilizando a ferramenta Knime, extraímos os dados da fonte e os carregamos para a área de staging. Nessa etapa, realizamos diversas transformações, como limpeza de dados duplicados, padronização de formatos e criação de novas colunas. Em paralelo,

iniciamos o planejamento para o carregamento incremental dos dados, que permitiria a atualização periódica.

- Integração com Ferramenta OLAP:
 - Após a conclusão do ETL e com o DW preparado, utilizamos o Google Looker como plataforma OLAP para análise e visualização dos dados. Os *dashboards* e relatórios do Looker transformaram as informações em insights acessíveis, permitindo uma análise detalhada das métricas e uma visão estratégica para a tomada de decisões. A ferramenta foi projetada para ser dinâmica, adaptando-se às necessidades dos diferentes usuários.

As etapas acima, aprendidas na experiência prática com a base Olist, foram, então, as mesmas etapas que seguimos no desenvolvimento do ambiente de tomada de decisão para o cenário real do PROLEM. As etapas mencionadas não devem ser entendidas como um padrão fixo, mas sim como um processo orgânico. Durante o desenvolvimento, fomos aprendendo e adaptando, o que nos levou a realizar ajustes, corrigir erros e incluir novos recursos com base no conhecimento que adquirimos.

3.2 Projeto Piloto

Como passo inicial de nosso projeto, optamos por um piloto com o objetivo de adquirir e aplicar os conhecimentos da fundamentação teórica em uma base de dados pública do sistema de E-commerce Olist, disponibilizada no Kaggle. A ideia era ganhar experiência e confiança para um cenário real, além de contornar os possíveis empecilhos burocráticos para conseguir acesso a uma base de dados real.

3.2.1 Etapas do projeto piloto

- Entendimento da Estrutura da Fonte de Dados:

- Primeiramente, buscamos entender a estrutura de armazenamento de nossa fonte de dados com o objetivo de entendê-la melhor e de buscar por assuntos que pudessem ser nossos assuntos de interesse. Estes assuntos se tornaram nossas tabelas de fato e as dimensões para análise, o que seria útil para a etapa de modelagem multidimensional. Em nossa fonte, tínhamos a organização das tabelas e seus relacionamentos como demonstrado na fonte KAGGLE (2024).
- Modelagem Inicial (Vendas):
 - Analisando a estrutura, percebemos que o assunto principal de interesse, que se liga com todas as demais informações, era o de vendas. Este foi o primeiro tema escolhido para o segundo passo do processo piloto, onde modelaríamos uma estrela e suas dimensões. Nesse caso, usamos o assunto venda como fato a ser analisado, vinculado a informações de dimensão de produto, cliente, vendedor e tempo. A partir daí, modelamos as métricas de venda da nossa tabela fato, que poderiam ser analisadas pelos atributos das dimensões modeladas.
- Aplicação de Arquitetura de Barramento:
 - Mais à frente, utilizamos tais dimensões com o objetivo de aplicar o conceito de arquitetura de barramento na construção de uma nova estrela a partir do barramento padrão, onde o fato de interesse seriam as avaliações feitas por cliente para cada venda. Chegamos, por fim, à modelagem demonstrada na figura 12.




Figura 12: Ilustração da Modelagem final feita

Fonte: Elaboração própria, 2024

- Construção do *Data Warehouse* e Staging Area:
 - A partir da modelagem do nosso esquema já feito, foi possível partir para o passo de construção do *Data Warehouse* e da nossa Staging Area. Iniciou-se o passo de desenvolvimento do ETL para a primeira carga do nosso DW. Para tal, utilizamos, na mesma instância de conexão ao armazenamento de dados que criamos o DW, um banco de apoio que usamos dentro do processo ETL. Além do ambiente do Knime, para a criação do workflow onde faríamos todo o processo de extração das fontes de dados, tratamento dos dados e posterior carregamento desses, ou diretamente ao DW, ou por meio do banco de apoio, que utilizamos como parte do ambiente de Staging Area para o carregamento de tabelas temporárias e, posteriormente, o carregamento das tabelas no DW. Na figura 13 É possível observar o diagrama gerado pelo gerenciador de banco de dados Dbeaver.
 - Estudo da Carga Incremental: Durante o desenvolvimento do ETL no projeto piloto, também estudamos a implementação da carga incremental, visando entender seu funcionamento e como ela poderia ser aplicada em um cenário

real. Para isso, simulamos uma carga inicial parcial dos dados e, em seguida, realizamos uma carga com os dados restantes, demonstrando o funcionamento do processo. Apesar de não termos aplicado a carga incremental no PROLEM, essa etapa foi valiosa para o nosso aprendizado.




Figura 13: Modelo Lógico do DW

Fonte: Elaboração própria, 2024

- Integração com Ferramenta OLAP (Looker Studio):
 - Já com o ambiente modelado, criado e com dados carregados, pudemos passar para a etapa final, onde fizemos a integração dos dados do DW com uma ferramenta OLAP para visualização dos dados, no caso, o Looker Studio. Nele, aplicamos algumas operações que facilitam as análises de dados pelos usuários, como a criação de tabelas de pivoteamento que permitem o acesso a diferentes níveis de granularidades de análise, além de permitir a flexibilidade da visualização de dados em que o usuário pode escolher a dimensão de análise através de filtros ou variáveis de escolha. Também permitimos que o

usuário possa navegar entre diferentes níveis de hierarquias que possibilitam as operações no cubo OLAP.

4 ESTUDO DE CASO

Utilizamos como nosso estudo de caso o Programa de Línguas Estrangeiras Modernas (PROLEM) da UFF que é um serviço de ensino de idiomas que oferece cursos de diversas línguas. O programa tem como objetivo proporcionar aos alunos a oportunidade de aprender e aperfeiçoar suas habilidades linguísticas, oferecendo cursos em diversos idiomas desde o inglês, francês, entre outros e em diferentes níveis de aprendizado.

Neste caso, utilizamos as técnicas fundamentada teoricamente no Capítulo 2 e aplicada metodologicamente conforme o Capítulo 3, para tornar o sistema OLTP já existente do PROLEM em um sistema já modelado multidimensionalmente que alimentaria uma ferramenta OLAP e no caso utilizamos da modelagem multidimensional para definição de um esquema ROLAP. Sendo este um sistema com objetivo de ser um facilitador nas análises de indicadores importantes para o programa de línguas estrangeiras que seria possibilitar analisar de forma mais amigável a quantidade de solicitações de inscrições e matrículas efetuadas, e assim poder visualizar a taxa de conversão de matrícula em inscrição. Além de possibilitar análises de evasão de matrículas através do acompanhamento de cancelamentos das mesmas ao longo do semestre, dentre outros indicadores. Podendo assim possibilitar a secretaria do programa entender melhor possíveis pontos de melhoria.

4.1 Preparação e descaracterização dos dados

Antes de começarmos a desenvolver o projeto de fato foi necessário que tivéssemos uma preocupação em especial com o tratamento dos dados sensíveis que existem no sistema do PROLEM. Para a descaracterização dos dados utilizamos algumas bibliotecas do Python para que pudéssemos automatizar o processo e gerar um *dump* descaracterizado. Sendo elas a *pymysql*, *sqlalchemy*, *faker*, *cpf_generator*, *difflib*, *hashlib* e por fim a biblioteca *pandas*. Onde a biblioteca *pandas* era responsável por manipular os data frames a partir da leitura em SQL da tabela que iríamos utilizar que foi feita através do *pymysql* que permitiu manipulação de linguagem SQL e do *sqlalchemy* que permitia conexão com o banco de dados que tinha a base

de dados real a ser descaracterizada criando uma cadeia de conexão com os dados necessários. Já as demais bibliotecas foram utilizadas no processo para gerar dados descaracterizados.

Dessa forma foi possível gerar um script onde passávamos as tabelas e os campos com dados sensíveis que iríamos realizar a descaracterização. Foi utilizado um ambiente em nuvem para que pudéssemos desenvolver em conjunto o script e também a fim de facilitar a configuração do ambiente de desenvolvimento, onde criamos um notebook no Google Collab com as células de configuração do ambiente e com o script responsável pelo processo de alteração dos dados.

Este processo se fez necessário dado o objetivo de trabalhar em conjunto com a base de dados armazenados em nuvem e sendo assim feita como uma medida de proteção dos dados cedidos ao projeto que ao serem publicados em ambiente em nuvem passariam a estar ainda mais sujeitos a violação da segurança da informação.

4.2 Entendendo o sistema do estudo de caso e definindo assuntos de interesse

Logo após gerarmos uma base de dados já descaracterizada e podermos seguir em frente com o desenvolvimento, foi essencial que houvesse entendimento do sistema do PROLEM assim como as regras de negócio definidas e como funcionam os trâmites do programa. Definindo qual era o escopo do sistema, que tipo de dados ele cobria, como eram organizados os dados no sistema visando principalmente que entendêssemos também as necessidades do programa e como poderíamos suprir essas necessidades com a informação que tínhamos em mão.

Contamos com a ajuda de nosso orientador que conhecia boa parte dos trâmites do programa por participar do projeto de desenvolvimento do sistema de armazenamento do mesmo. Este pode exercer um papel de especialista e nos explicar como funcionava o programa e como era o processo de inscrição do início ao fim no que diz respeito às tratativas do sistema de armazenamento.

Para que então pudéssemos olhar a base de dados e procurar entender como era o diagrama de organização das tabelas a fim de entender ainda melhor o sistema e buscar possíveis assuntos de interesse que seriam levados em pauta durante nossas reuniões e depois

serem levados em discussão com os integrantes da secretaria do PROLEM para entender possíveis pontos de dúvidas dos trâmites do programa e principalmente alinhar se os assuntos de interesse por nós definidos também eram de interesse de análise para o programa. E assim chegar a uma definição de interesses em comum, definindo como nosso assunto principal de interesse todo o ciclo de vida de uma solicitação de inscrição no sistema.

4.3 Desenvolvimento do Diagrama de Transição de estados (DTE)

Após definirmos um assunto de interesse, conforme definido na seção anterior (4.2 Entendendo o sistema do estudo de caso e definindo assuntos de interesse), optamos por ter uma etapa de pré-modelagem com o desenvolvimento de um diagrama de transição de estados (DTE), que é um diagrama que nos permite acompanhar as mudanças de estado ou comportamento que um sistema se encontra ao longo da execução de ações ou processos.

Com o objetivo de mapear todas as mudanças de estados que acontecem ao longo do ciclo de vida de uma inscrição no sistema do PROLEM e entender quais mudanças de fluxo ocorriam a partir do estado inicial de uma solicitação de inscrição até um eventual estado terminal. E a partir disso poder definir com mais clareza o que seria mapeado em nossa modelagem, na Figura 14 apresenta uma versão resumida do diagrama de transição de estados, focando nos estados mais relevantes para o nosso assunto de interesse. Essa versão simplificada foi elaborada para proporcionar uma visualização mais clara e direta, com o objetivo de facilitar o entendimento do fluxo principal dos eventos. (a [versão completa](#) do diagrama está disponível no link).




Figura 14: Diagrama de estados

Fonte: Elaboração própria, 2025

E a partir dessa pré-modelagem podemos chegar numa modelagem final dos estados que uma solicitação assume no sistema que poderiam ser representados no esquema ROLAP de saída da modelagem multidimensional a ser feita logo em seguida.

4.4 Modelagem Multidimensional

Como dito anteriormente, a partir da pré-modelagem feita com o DTE, como demonstrado na seção anterior (4.3 Desenvolvimento do Diagrama de Transição de estados (DTE)), e com a definição do assunto de interesse anteriormente a isso tendo sido feita, podíamos partir para a modelagem do esquema ROLAP de saída. Definimos então uma tabela de fato principal, que seria uma tabela de fatos sem fato (*Factless Fact Table*), ou seja, uma tabela de fato que não possui nada além de chaves estrangeiras para as tabelas de dimensão. O objetivo da definição de uma tabela fato desse tipo se deu pela necessidade de acompanhamento de eventos que acontecem no ciclo de vida de inscrição de um aluno no PROLEM ou seja o interesse é muito maior em ter um rastreio do fluxo de eventos que acontecem do que mapear alguma métrica relacionada a cada solicitação do aluno ao longo do processo de inscrição, logo uma tabela de fato sem fatos nesse caso se encaixa perfeitamente com o que precisamos.

A partir dessa definição mapeamos alguns dos estados que a solicitação do aluno pode se encontrar ao longo do ciclo de vida da inscrição com base no DTE desenvolvido em eventos de uma tabela de dimensão de eventos que caracterizaria o estado em que aquela solicitação do aluno se encontra no sistema de origem. Seguido de um barramento padrão de tabelas de dimensão de aluno, curso, instrutor, tempo.

4.5 ETL

No desenvolvimento do fluxo de ETL para o PROLEM, nossa prioridade foi capturar os principais eventos de solicitação do sistema, seguindo o fluxo principal definido no

Diagrama de Transição de Estados (DTE). Assim, concentramos a extração nos eventos de solicitação de inscrição, matrícula, cancelamento e conclusão de curso, pois eles representam marcos significativos no ciclo de vida do aluno, sem a necessidade de detalhar cada pequena mudança de estado.

A extração de dados foi realizada diretamente no banco de dados MySQL de backup do PROLEM, usando consultas SQL específicas para cada tipo de evento. Essa etapa foi feita no ambiente da ferramenta Knime, que também serviu como nossa plataforma para a execução de todo o processo de ETL. Essa abordagem nos permitiu manter um fluxo de trabalho consistente, aproveitando a experiência e o conhecimento que já havíamos adquirido durante o projeto piloto.

Na etapa de transformação, os dados extraídos passaram por diversas etapas de preparação para garantir a consistência e a adequação ao modelo dimensional do DW, mas, pelo fato de que nossa fonte de dados era um *dump* de um banco de dados, o tratamento se mostrou mais simples em relação ao caso piloto. Após a extração e transformação dos dados, Apresenta-se a estrutura do fluxo de ETL que nos permitiu carregar os dados no *Data Warehouse*. A Figura 15 demonstra o início do fluxo de carregamento da tabela de fatos, onde é possível observar a junção de dados de diferentes consultas através da conexão com o banco pelo nó *MySQL Connector* e o nó *Query Reader* de leitura das tabelas via consulta SQL, onde inicialmente, foram extraídas informações sobre as solicitações de inscrição, matrículas efetivadas, solicitações de cancelamento e matrículas que concluíram o curso, sendo este o fluxo principal do prolem.

E onde cada um destes eventos é representado por um fluxo diferente após o nó de conexão com o banco para a extração dos dados. Além disso, foi atribuído um identificador para cada tipo de evento através do nó *Constant Value Column* para caracterização dos eventos já definidos na tabela de dimensão de eventos, e, em seguida, todas as informações foram combinadas através de nó *Concatenate*. E ao final do fluxo na figura 16, os dados das dimensões foram carregados e juntos através de nós de *Joiners* além de terem sido realizados outros nós de transformações e ajustes dos dados, para o carregamento no DW modelado com nó *DB Writer*.




Figura 15: ETL da fato - Parte 1

Fonte: Elaboração própria, 2024




Figura 16: ETL da fato - Parte 2

Fonte: Elaboração própria, 2024

Essas figuras representam a estrutura geral do fluxo de ETL e ilustram como os dados foram extraídos, transformados e preparados para o carregamento no *Data Warehouse*, com o objetivo de criar um ambiente onde as informações possam ser analisadas em diferentes perspectivas. A preparação dos dados, realizada com o Knime, permite que as ferramentas de análise como o Looker Studio, Power BI ou outros, explorem as informações e gerem *insights* valiosos para o PROLEM.

tratamentos. Feito isso já podemos ir ao próximo passo de construção dos indicadores de interesse definidos após reunião com a secretaria do PROLEM e principalmente seguindo de acordo com o fluxo principal que definido no DTE e prezando por medidas que quantificassem o ciclo de inscrições dos alunos como quantidade de inscrições, matrícula, conclusões e cancelamentos de matrícula. Para a partir daí gerar medidas que pudessem facilitar a análise de adesão dos alunos com a taxa de conversão de inscrições em matrícula, ou conversão de matrículas em cancelamentos para análise de evasão do programa e conversão de matrícula em concluintes que possibilitaria uma análise de desempenho dos alunos. Sendo esta só um pequeno grupo de medidas e análises que foram definidas de acordo com o assunto de interesse definido, que era acompanhamento do ciclo de inscrição em tempo real.

Logo, com os indicadores criados se tornou possível a criação das primeiras visualizações de dados através de gráficos que permitem aos usuários ver os indicadores sobre as diferentes dimensões carregadas. Permitindo então que sejam feitas as operações que uma ferramenta OLAP permite como slice, dice através da utilização de filtros e segmentação flexível de indicadores criados, além de operações de *drill down* ou *up* para andar pela hierarquia da dimensão tempo para visualizar os indicadores sobre diferentes períodos de tempo. Como podemos ver na figura abaixo, na primeira versão da ferramenta OLAP que torna muito mais amigável a visualização dos dados aos usuários finais e permite ao mesmo maior facilidade para análise dos dados.



Figura 19: Dashboard finalizado

Fonte: Elaboração própria, 2024

5 CONCLUSÃO

Essa monografia teve como objetivo principal apresentar o desenvolvimento de um sistema de apoio à tomada de decisão utilizando os conceitos da modelagem multidimensional. Ao longo deste percurso, exploramos os principais fundamentos teóricos e práticos que sustentam a construção de um *Data Warehouse*, desde a modelagem dimensional até a implementação do processo de ETL e a utilização de ferramentas OLAP.

Nossa pesquisa abrangeu, conforme demonstrado no capítulo 2, o estudo teórico das técnicas de modelagem dimensional, quanto a sua aplicação em um caso real demonstrado no capítulo 4. Para isso, percorremos um caminho que iniciou com a aplicação da teoria em um contexto piloto, no qual foram descritas do capítulo 3, usando base de dados pública do Olist, onde pudemos fixar nossos conhecimentos sobre o processo de construção de um ambiente de apoio à decisão. As etapas de extração, transformação e carga (ETL), modelagem das dimensões e da tabela fato, construção da Staging Area, e uso de ferramentas de visualização OLAP foram cruciais para solidificar nossa compreensão das metodologias envolvidas no desenvolvimento de um *Data Warehouse*.

A aplicação dessas metodologias no contexto do PROLEM demonstrou a viabilidade da modelagem multidimensional para transformar dados operacionais em informações estratégicas. A construção do esquema ROLAP, com a definição da tabela de fato sem fato para o acompanhamento do ciclo de vida de uma solicitação no PROLEM, permitiu explorar a estrutura de dados de forma mais analítica e com o sistema modelado, o processo de ETL foi implementado utilizando a ferramenta Knime, onde realizamos a extração dos dados do banco de dados MySQL de backup do PROLEM, a transformação dos dados visando a consistência para um sistema ROLAP.

Os dados foram disponibilizados em um ambiente OLAP que permitiu gerar dashboards e relatórios que poderiam ser utilizados pelos gestores do PROLEM para facilitar com que a secretaria do programa pudesse ter de forma automatizada ao invés de contabilizar de forma manual o acesso a informações sobre solicitações de inscrição, matrículas, cancelamentos e conclusões de curso. E apenas com a interação no dashboard pudessem analisar em tempo real aspectos de interesse debatidos em reunião como a adesão, evasão e desempenho dos alunos nos diferentes cursos oferecidos.

Porém a ausência de uma reunião com o PROLEM para avaliar o impacto do sistema desenvolvido no processo de tomada de decisão, devido ao tempo de realização do estudo, impediu que o dashboard fosse apresentado a secretaria do programa a fim de confirmar se os resultados gerados e disponibilizados foram ou não adequados para suas necessidades e se atenderam as expectativas, ficando assim como um passo futuro a ser executado.

Assim como outros passos de expansão do modelo dimensional do PROLEM, abordando mais assuntos de interesse também definidos na reunião com a equipe do programa. E também explorar as possibilidades de análise e visualização que as ferramentas OLAP oferecem através de uma avaliação com usuários reais do sistema. E possibilitando assim mensurar o verdadeiro impacto e valor das informações extraídas para a tomada de decisões estratégicas.

Logo nesse sentido, este trabalho representou um importante avanço no aprendizado das metodologias de criação de sistemas de apoio à decisão, e, em especial, no entendimento da importância de um levantamento do processo de negócio, pois a etapa que mais demandou tempo foi o entendimento da estrutura da base de dados do sistema e das regras de negócio, para poder gerar um modelo que fizesse sentido para as necessidades da organização. Um aprendizado valioso foi entender que a colaboração de pessoas que conhecem a fundo o negócio é fundamental para que possamos construir um sistema que atenda às necessidades de informação dos usuários, o que ficou claro em nossa reunião com o PROLEM, que identificou outros possíveis fatos que poderiam ser explorados em trabalhos futuros.

Por fim, acreditamos que este trabalho contribuiu para o avanço na área de Sistemas de Apoio à Decisão e da análise de dados. Demonstrando na prática que a transformação de dados brutos em informações estratégicas é um passo fundamental para a melhoria contínua das organizações e apoio na tomada de decisões como no caso do PROLEM. Que com a ferramenta OLAP desenvolvida poderia ter ganho em fatores de diminuição de tempo de trabalho para se gerar indicadores de interesse, além de acesso a análises de assuntos de interesse em tempo real para que o programa possa implementar melhorias de processo com base nas informações de adesão, evasão e desempenho dos alunos no programa ainda durante cada semestre. Algo que o dashboard passou a permitir.

REFERÊNCIAS

AVANCINI, D. **Dimensão de Alteração Lenta (SCD). Engenharia de *Analytics***. Disponível em: <<https://www.engdeanalytics.com.br/chapters/10/02/scd.html>>. Acesso em: 8 jul. 2024.

CÓDIGO FONTE TV. ***Data Warehouse / Data Lake / Data Lakehouse // Dicionário do Programador***. Disponível em: <<https://www.youtube.com/watch?v=V07Pk4de-5M>>. Acesso em: 2 set. 2024.

DEVMEDIA. **Artigo SQL Magazine 9 - Arquiteturas de Ferramentas OLAP**. Disponível em: <<https://www.devmedia.com.br/artigo-sql-magazine-9-arquiteturas-de-ferramentas-olap/7565>>. Acesso em: 24 set. 2024.

GALVÃO, J. **Modelagem de Dados aplicada em ambiente de *Data Warehouse* – Dimensões Descaracterizadas e Modelo *Snowflake***. Disponível em: <<https://pedrogalvaojunior.wordpress.com/2023/07/07/modelagem-de-dados-aplicada-em-ambiente-de-data-warehouse-dimensoes-descaracterizadas-e-modelo-snowflake/>>. Acesso em: 21 dez. 2024.

KAGGLE. ***Brazilian E-Commerce Public Dataset by Olist***. Disponível em: <<https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce/data>>. Acesso em: 8 jul. 2024.

KIMBALL, R.; ROSS, M. ***The Data Warehouse Toolkit***. Hoboken: John Wiley & Sons, 2011.

LOPES, F. **Arquitetura de Barrame... | Base de Conhecimento**. Disponível em: <<https://kb.ufla.br/books/termos-e-definicoes-governanca-de-dados/page/arquitetura-de-barramento-do-enterprise-data-warehouse>>. Acesso em: 8 jul. 2024.

ROCHA, K. **O que é OLAP e como ele é utilizado na Tecnologia da Informação**. Disponível em: <<https://www.estrategiaconcursos.com.br/blog/o-que-e-olap/>>. Acesso em: 24 set. 2024

ROSS, M. *Design Tip #152 Slowly Changing Dimension Types 0, 4, 5, 6 and 7*. Disponível em: <<https://www.kimballgroup.com/2013/02/design-tip-152-slowly-changing-dimension-types-0-4-5-6-7/>>. Acesso em: 8 jul. 2024.

SANTANA, E. **Bufallos**. Disponível em: http://bufallos.com.br/bg_br/conheca-etl/. Acesso em: 21 dez. 2024.

SANTOS, P. **O Que É Esquema Estrela (Star Schema)?** Disponível em: <<https://cadernodeprova.com.br/esquema-estrela-star-schema/>>.

WIKIPÉDIA. **Processamento analítico on-line**. Disponível em: <https://fr.wikipedia.org/wiki/Traitement_analytique_en_ligne>. Acesso em: 24 set. 2024.